

BÜYÜK VERİ ANALİZİNE GİRİŞ DÖNEM PROJESİ TEKNİK RAPORU

Konu: Chicago Suç Veri Seti ile Uçtan Uca Kappa Mimarisi, Medallion Veri Hattı ve Dağıtık Makine Öğrenmesi Sistemi

Hazırlayanlar: Ahmet Kayra Gügercin, Oğuz Gözütok, Cüneyt Oğuz Başkurt, Yusuf Berkay Acar

Tarih: 13 Mayıs 2026

1. GİRİŞ VE PROJE MOTİVASYONU

Modern metropollerde güvenlik stratejilerinin belirlenmesi, büyük veri analitiği ve makine öğrenmesi modellerinin çıktılarına dayanmaktadır. Chicago şehri, 2001 yılından bu yana düzenli olarak paylaştığı suç veri setiyle bu alandaki akademik çalışmalar için altın standart niteliğindedir.

Bu projenin temel motivasyonu, sadece statik bir veri analizi yapmak değil, saniyede onlarca suç kaydının sisteme düştüğü senaryoyu simüle eden profesyonel bir **Kappa Mimarisi** kurmaktır. Proje, ham verinin yutulmasından (ingestion), işlenmesine ve canlı bir dashboard üzerinden sunulmasına kadar olan tüm aşamaları endüstriyel araçlar kullanarak otomatize etmiştir.

2. SİSTEM MİMARİSİ

Sistemimiz, mikro hizmet mimarisi prensiplerine uygun olarak Docker konteynerleri üzerinde izole edilmiştir.

2.1. Veri Üretimi ve Mesaj Kuyruğu (Kafka)

Gerçek zamanlı akışı simüle etmek adına, yerel diskteki CSV verisi bir **Kafka Producer** tarafından okunmaktadır. Veri tutarlılığını sağlamak ve Spark tarafında paralellliği artırmak için crimes topic'i 3 farklı partisyona bölünmüştür. Bu sayede veri hattında oluşabilecek darboğazların (bottleneck) önüne geçilmiştir.

2.2. Akış İşleme Motoru (Apache Spark)

Spark Structured Streaming kullanılarak, Kafka'dan gelen veriler 10 saniyelik "micro-batch" aralıklarla işlenmektedir. Bu aşamada verinin sadece "şimdi"si değil, "stateful" olarak geçmişle olan bağı da Delta Lake üzerinden korunmaktadır.

2.3. Depolama Katmanı (Delta Lake - Medallion Architecture)

Delta Lake, geleneksel veri göllerinin aksine ACID garantisi sunarak veri bozulmalarını engeller.

- Bronze Katmanı:** Kaynaktan gelen ham JSON'lar; denetim (audit) ve olası hata

durumlarında veriyi geriye dönük işleyebilmek (re-processing) amacıyla saklanır.

- **Silver Katmanı:** Şema zorlama (Schema Enforcement) uygulanarak verinin kalitesi garanti altına alınır. Boş (null) değerler ve anomali içeren kayıtlar bu aşamada ayıklanır.
- **Gold Katmanı:** İş birimlerinin ve ML modellerinin doğrudan sorgu atabileceği, özellik mühendisliği tamamlanmış en yüksek kalitedeki tablodur.

3. VERİ İŞLEME VE GELİŞMİŞ ÖZELLİK MÜHENDİSLİĞİ

Makine öğrenmesi modellerinin "çöp içeri, çöp dışarı" (garbage in, garbage out) prensibine takılmaması için Gold katmanına giden yolda veri zenginleştirilmiştir.

1. **Zaman Analizi:** Date sütunu; Hour (Suç saati), DayOfWeek (Haftanın günü) ve IsWeekend (Hafta sonu etkisi) olarak parçalanmıştır. Bu sayede modelin zaman tabanlı paternleri öğrenmesi sağlanmıştır.
2. **Kategorik Kodlama:** Primary Type ve Location Description gibi yüksek kardinaliteli metin verileri, StringIndexer ve OneHotEncoder boru hatları kullanılarak vektörel forma sokulmuştur.
3. **Coğrafi Normalizasyon:** Enlem ve boylam verileri, modelin mesafe farklarını daha iyi anlayabilmesi için normalizasyon sürecinden geçirilmiştir.

4. MAKİNE ÖĞRENMESİ VE DENEY YÖNETİMİ

Proje kapsamında 5 farklı dağıtık algoritma karşılaştırılmıştır. Deneylerin her biri **MLflow** sunucusunda ayrı birer "Run" olarak kaydedilmiştir.

4.1. Model Performans Karşılaştırması

Aşağıdaki tablo, modellerin test veri seti üzerindeki performansını özetlemektedir:

Algoritma	Doğruluk (Accuracy)	AUC-ROC	F1-Score
GBTClassifier	%91.74	0.9258	%90.04
Decision Tree	%90.64	0.2921	%89.09
Logistic Regression	%87.54	0.8487	%86.08
Random Forest	%86.69	0.8746	%81.10
Naive Bayes	%30.40	0.5939	%31.09

4.2. Model Değerlendirmesi

Gradyan Artırılmış Ağaçlar (GBT), zayıf öğrencileri birleştirerek karmaşık karar sınırları

oluşturmuş ve tutuklama tahmininde en yüksek başarıyı elde etmiştir. Naive Bayes'in düşük performansı, özellikler arasındaki bağımsızlık varsayımının bu veri seti için geçerli olmamasından kaynaklanmaktadır.

5. TEKNİK ZORLUKLAR VE İNOVATİF ÇÖZÜMLER

Geliştirme aşamasında karşılaşılan engeller, projenin en öğretici kısımlarını oluşturmuştur:

5.1. Negatif Koordinat ve Naive Bayes Çökmesi

- **Problem:** Chicago'nun boylam verileri negatiftir. Spark ML Naive Bayes, varsayılan olarak Multinomial dağılım bekler ve negatif sayıları reddeder.
- **Çözüm:** Modelin matematiksel altyapısı, sürekli verileri Gaussian dağılımıyla işleyen yapıya güncellenmiştir. Bu yama, eğitim hattının kesintisiz çalışmasını sağlamıştır.

5.2. Streamlit - Spark Konfigürasyon Senkronizasyonu

- **Problem:** Streamlit arayüzü, web üzerinde her etkileşimde (button click) sayfayı yeniler. Bu durum Spark session kilitlenmelerine ve Delta Lake JAR dosyalarının yüklenememesine yol açmıştır.
- **Çözüm:** os.environ üzerinden PYSARK_SUBMIT_ARGS değişkenine Delta kütüphaneleri çalışma zamanında enjekte edilmiştir. JVM'nin dinamik sınıf yükleyicisi manuel olarak kontrol edilerek bu kısıt aşılmıştır.

6. GELECEK ÇALIŞMALAR VE DEĞERLENDİRME

Proje, şu geliştirmelere açıktır:

1. **Zaman Serisi Analizi:** Prophet veya ARIMA modelleriyle suç yoğunluğu tahmini.
2. **Derin Öğrenme:** PyTorch veya TensorFlow ile daha karmaşık sinir ağlarının entegrasyonu.
3. **Bulut Entegrasyonu:** Sistemin Azure Databricks veya AWS EMR üzerinde ölçeklendirilmesi.

Sonuç olarak; Chicago Suç Tahmin Sistemi, büyük veri araçlarının (Kafka, Spark, Delta) bir senfoni gibi uyum içinde çalışabileceğini kanıtlayan, %91 başarı oranına sahip uçtan uca profesyonel bir veri hattıdır.